

Micro-reto: su propio pipeline de ETL

Módulo II · Sesión de cierre — Adquisición y exploración de datos

■ El reto

Van a construir, en SQL, su propio pipeline ETL con arquitectura medallion (bronce → plata → oro), usando el dataset **declaraciones_importacion_500.parquet**. Al final, van a automatizarlo con un Job de Databricks. Este es el mismo proceso que acaban de ver en la demo — ahora les toca a ustedes.

Pregunta que su pipeline debe responder

¿Cómo se comporta el valor de las importaciones por subpartida arancelaria y país de origen? — esta pregunta conecta con el proyecto transversal del curso.

El dataset

declaraciones_importacion_500.parquet contiene declaraciones de importación sintéticas — nunca es información real de la DIAN. Al igual que el dataset de la demo, **tiene problemas de calidad a propósito**: valores nulos, filas duplicadas, texto con mayúsculas/espacios inconsistentes, y algunos valores negativos que no deberían existir. Su primer trabajo es encontrarlos antes de limpiarlos.

Pasos a seguir

- 1 **EXTRACT:** creen la tabla bronce apuntando al archivo parquet (usen `CREATE TABLE ... USING PARQUET`).
- 2 **EXPLORE:** antes de limpiar nada, midan el problema: ¿cuántas filas duplicadas hay? ¿qué columnas tienen nulos? ¿qué variantes de texto existen en columnas como `tipo_importador`, `departamento`, `ciudad` o `pais_origen`? ¿hay valores negativos donde no deberían?
- 3 **TRANSFORM:** construyan la tabla plata resolviendo, uno por uno, los problemas que encontraron en el paso anterior. Piensen qué función de SQL resuelve cada problema (`TRIM`, `INITCAP`, `COALESCE`, `ABS`, `ROW_NUMBER`...).
- 4 **VALIDATE:** comparen conteos entre bronce y plata para demostrar que su limpieza funcionó.
- 5 **LOAD:** construyan la tabla oro que responda la pregunta de negocio — agregada por subpartida arancelaria y país de origen.
- 6 **AUTOMATIZAR:** creen un Job que ejecute su notebook completo, y tomen una captura de un Run exitoso.

■ Pista

En la demo, la tabla plata se construyó con un patrón que pueden reutilizar: un CTE con ROW_NUMBER() para quitar duplicados, y luego un SELECT que aplica TRIM/INITCAP a las columnas de texto y COALESCE/ABS a las columnas numéricas. La estructura es la misma — cambian las columnas.

Entregable

- Notebook (.py o .sql) con las 5 tablas: bronze, silver, gold y las consultas de perfilamiento/validación.
- Captura de pantalla del Job ejecutado exitosamente (estado Succeeded).
- Una frase corta (2-3 líneas) respondiendo la pregunta de negocio con lo que muestra su tabla oro.